

# **SISTEMATIZACIÓN Y METODOS ESTADISTICOS S2**

## **TRABAJO 2 - PC1**




### **DOCENTE**

- **Castro Lopez, Segundo Vicente**

# INTEGRANTES - GRUPO I

- Avilés Magallanes, María Fernanda
- Cassane Acevedo, Naomi Adriana
- Dieguez Tasayco, Nallely Mirella
- Medina Li, Margaret Belén
- Moreyra Llancari, Diana Melisa
- Quispe Berrocal Luigy
- Wincho Rojas Omar



The screenshot shows the RStudio interface. The top menu bar includes File, Edit, Code, View, Plots, Session, Build, Debug, Profile, Tools, and Help. Below the menu is a toolbar with icons for file operations and a search bar. The main editor window has a title bar with several open files: 'almac\_sangre', 'AVILES\_MARIA\_GRUPO\_1.qmd', 'almac\_sangre\_1', and 'almac\_sangre\_2'. The 'Visual' tab is selected, showing a document with the title 'ANTES DE LA LIMPIEZA'. Below the title, a code chunk is visible with the following content:


```
{r}
str(almac_sangre)
```

The output of the code is displayed in a separate window, showing the structure of the 'almac\_sangre' data frame. It is a data frame with 316 observations and 20 variables. The variables and their data types are listed as follows:

- \$ Grupo\_edad\_GR: chr "Mayor" "Mayor" "Mayor" "Intermedio" ...
- \$ Edad\_mediana\_GR: int 25 25 25 15 15 25 25 10 10 15 ...
- \$ Edad: num 72.1 73.6 67.5 65.8 63.2 65.4 65.5 67.1 63.9 63 ...
- \$ Raza\_afroamericana: chr "No" "No" "No" "No" ...
- \$ Historia\_familiar: chr "No" "No" "No" "No" ...
- \$ Volumen\_prostata: num 54 43.2 102.7 46 60 ...
- \$ Volumen\_tumoral: chr "Alto" "Alto" "Bajo" "Bajo" ...
- \$ Estadio\_T: chr "T1-T2a" "T2b-T3" "T1-T2a" "T1-T2a" ...
- \$ Gleason\_biopsia: chr "Gleason 8-10" "Gleason 7" "Gleason 8-10" "Gleason 0-6" ...
- \$ Confinamiento\_organo: chr "No" "Sí" "Sí" "Sí" ...
- \$ PSA\_preoperatorio: num 14.08 10.5 6.98 4.4 21.4 ...
- \$ Terapia\_previa: chr "Sí" "No" "Sí" "No" ...
- \$ Unidades\_transfundidas: int 6 2 1 2 3 1 2 4 1 2 ...
- \$ Gleason\_quirurgico: chr "No asignado" "Gleason 7" "No asignado" "Gleason 7" ...
- \$ Terapia\_adyuvante: chr "No" "No" "No" "No" ...
- \$ Radioterapia\_adyuvante: chr "No" "No" "No" "No" ...
- \$ Recurrencia\_bioquimica: chr "Sí" "Sí" "No" "No" ...

The bottom of the screenshot shows the 'Console' tab with the text 'meet.google.com está com'.

Este paso lo que hará es **INSTALAR** los paquetes que se van a emplear en la limpieza de la data base (almac\_sangre) Si en caso saliera error significa que ya esta instalado si no aparece el error indica que el paquete a sido instalado recién.



```
{r}
#PASO 2 ACTIVAR PAQUETES OBLIGATORIO

library(tidyverse)
library(rio)
library(here)
library(janitor)
```


— Attaching core tidyverse packages —

|                   |       |           |       |
|-------------------|-------|-----------|-------|
| tidyverse 2.0.0 — |       |           |       |
| ✓ dplyr           | 1.1.4 | ✓ readr   | 2.1.5 |
| ✓ forcats         | 1.0.0 | ✓ stringr | 1.5.1 |
| ✓ ggplot2         | 3.5.2 | ✓ tibble  | 3.3.0 |
| ✓ lubridate       | 1.9.4 | ✓ tidyr   | 1.3.1 |
| ✓ purrr           | 1.1.0 |           |       |

— conflicts —

```
tidyverse_conflicts() —
✗ dplyr::filter() masks stats::filter()
✗ dplyr::lag() masks stats::lag()
i use the conflicted package to force all conflicts to become errors
```

Este paso lo que harás ACTIVAR los paquetes que se van a emplear en la limpieza de la data base (almac\_sangre).



Este paso **IMPORTA** la data base en este caso (almac\_sangre).



RStudio

File Edit Code View Plots Session Build Debug Profile Tools Help

almac\_sangre AVILES\_MARIA\_GRUPO\_1.qmd almac\_sangre\_1 almac\_sangre\_2

Render on Save Render Run

Source Visual B I <> Normal Format Insert Table

## ANTES DE LA LIMPIEZA

```
{r}
str(almac_sangre)
```

```
'data.frame': 316 obs. of 20 variables:
 $ Grupo_edad_GR : chr "Mayor" "Mayor" "Mayor"
 "Intermedio" ...
 $ Edad_mediana_GR : int 25 25 25 15 15 25 25 10 10 15
 ...
 $ Edad : num 72.1 73.6 67.5 65.8 63.2 65.4
 65.5 67.1 63.9 63 ...
 $ Raza_afroamericana : chr "No" "No" "No" "No" ...
 $ Historia_familiar : chr "No" "No" "No" "No" ...
 $ Volumen_prostata : num 54 43.2 102.7 46 60 ...
 $ Volumen_tumoral : chr "Alto" "Alto" "Bajo" "Bajo" ...
 $ Estadio_T : chr "T1-T2a" "T2b-T3" "T1-T2a" "T1-
T2a" ...
 $ Gleason_biopsia : chr "Gleason 8-10" "Gleason 7"
 "Gleason 8-10" "Gleason 0-6" ...
 $ Confinamiento_organo : chr "No" "Sí" "Sí" "Sí" ...
 $ PSA_preoperatorio : num 14.08 10.5 6.98 4.4 21.4 ...
 $ Terapia_previa : chr "Sí" "No" "Sí" "No" ...
 $ Unidades_transfundidas : int 6 2 1 2 3 1 2 4 1 2 ...
 $ Gleason_quirurgico : chr "No asignado" "Gleason 7" "No
asignado" "Gleason 7" ...
 $ Terapia_adyuvante : chr "No" "No" "No" "No" ...
 $ Radioterapia_adyuvante : chr "No" "No" "No" "No" ...
 $ Recurrencia_bioquimica : chr "Sí" "Sí" "No" "No" ...
 $ Censor : chr "No" "No" "Sí" "Sí"
```

Chunk 1

meet.google.com está comparti

**COMANDO STR** nos da un resumen de todos los datos y las variables de (almac\_sangre).

## LIMPIEZA DE LA TABLA

### PASO 1: Correccion antes de corregir datos

- Corregir nombres de variables ponerlos en minuscula y usar guiones
- Colocar las celdas vacias en caso hubieran NA
- Eliminar columnas o filas vacias

```
{r}  
almac_sangre_1 = almacen_sangre |>  
  clean_names() |>  
  mutate_if(is.character, list(~ na_if(., ""))) |>  
  remove_empty(which = c("rows", "cols"))
```

#### **clean\_names()**

- Limpia los nombres de las columnas
- Convierte a minúsculas
- Reemplaza espacios y caracteres especiales con guiones bajos

#### **mutate\_if(is.character, list(~ na\_if(., "")))**


- Aplica una función a todas las columnas que sean de tipo carácter
- Convierte strings vacíos "" en valores NA

#### **remove\_empty(which = c("rows", "cols"))**

- Elimina filas que estén completamente vacías
- Elimina columnas que estén completamente vacías



# PARTE 1



**PASO 2: Corregir datos:**

- Reemplazar edad de números decimales a enteros
- Estandarizar no asignado por NA
- Estandarizar "SI"NO en todas las columnas.
- Reemplazar tiempo de recurrencia decimales a enteros

```
{r}
library(dplyr)

# Crear almac_sangre_1 con todas las correcciones
almac_sangre_2 <- almac_sangre |>
# Convertir edad de decimales a enteros (redondeando)
mutate(Edad = round(Edad)) |>

# Estandarizar "No asignado" por NA en columnas de Gleason
mutate(across(
  c(Gleason_biopsia, Gleason_quirurgico),
  ~ case_when(
    .x == "No asignado" ~ NA_character_,
    TRUE ~ as.character(.x)
  )
)) |>

# Estandarizar "Sí"/"No" en todas las columnas categóricas
```

## library(dplyr)

- Carga el paquete dplyr - una herramienta esencial para manipulación de datos en R
- Permite usar funciones como mutate(), across(), case\_when(), y el operador pipe |> almac\_s

## Toma el dataframe original almac\_sangre

- Toma el dataframe original almac\_sangre
- Usa el operador pipe |> para pasar los datos a las siguientes operaciones
- EL RESULTADO FINAL SE GUARDARÁ EN UN NUEVO DATAFRAME LLAMADO ALMAC\_SANGRE\_2

## mutate(Edad = round(Edad)) |>

- mutate() crea o modifica columnas
- round(Edad) redondea los valores decimales de la columna Edad al entero más cercano



## PARTE 2

```
mutate(across(
  c(Gleason_biopsia, Gleason_quirurgico),
  ~ case_when(
    .x == "No asignado" ~ NA_character_,
    TRUE ~ as.character(.x)
  )
)) |>
```

across() aplica la misma transformación a múltiples columnas

c(Gleason\_biopsia, Gleason\_quirurgico) especifica las columnas a transformar

Si el valor es "No asignado" → lo convierte a NA

TRUE (cualquier otro caso) → mantiene el valor original

```
mutate(across(
  c(Raza_afroamericana,          Historia_familiar,
    Confinamiento_organo,
    Terapia_previa,              Terapia_adyuvante,
    Radioterapia_adyuvante,
    Recurrencia_bioquimica, Censor, BN_positivo),
  ~ case_when(
```

```
x %in% c("Sí", "Si", "SI", "sí", "si", "S", "s") ~ "SI",
.x %in% c("No", "NO", "no", "N", "n") ~ "NO",
TRUE ~ as.character(.x)
)
)) |>
```


Aplica a 9 columnas con respuestas binarias

%in% verifica si el valor está en la lista proporcionada

- **Convierte múltiples variantes ("Sí", "Si", "SI", etc.) a "SI" estandarizado**
- **Convierte múltiples variantes ("No", "NO", "no", etc.) a "NO" estandarizado**
- Mantiene otros valores como están (por si hay algún valor inesperado)

```
mutate(Tiempo_hasta_recurrencia =
  round(Tiempo_hasta_recurrencia))
```

Redondea los valores decimales de la columna Tiempo\_hasta\_recurrencia



RStudio

File Edit Code View Plots Session Build Debug Profile Tools Help

almac\_sangre AVILES\_MARIA\_GRUPO\_1.qmd almac\_sangre\_1 almac\_sangre\_2

Render on Save Render

Source Visual B I </> Normal Format Insert Table

## DESPUES DE LA LIMPIEZA

Para verificar de una forma facil los cambios

```
{r}
str(almac_sangre_2)
```

```
'data.frame': 316 obs. of 20 variables:
 $ Grupo_edad_GR : chr "Mayor" "Mayor" "Mayor"
 "Intermedio" ...
 $ Edad_mediana_GR : int 25 25 25 15 15 25 25 10 10 15
 ...
 $ Edad : num 72 74 68 66 63 65 66 67 64 63
 ...
 $ Raza_afroamericana : chr "NO" "NO" "NO" "NO" ...
 $ Historia_familiar : chr "NO" "NO" "NO" "NO" ...
 $ Volumen_prostata : num 54 43.2 102.7 46 60 ...
 $ Volumen_tumoral : chr "Alto" "Alto" "Bajo" "Bajo" ...
 $ Estadio_T : chr "T1-T2a" "T2b-T3" "T1-T2a" "T1-
T2a" ...
 $ Gleason_biopsia : chr "Gleason 8-10" "Gleason 7"
 "Gleason 8-10" "Gleason 0-6" ...
 $ Confinamiento_organo : chr "NO" "SI" "SI" "SI" ...
 $ PSA_preoperatorio : num 14.08 10.5 6.98 4.4 21.4 ...
 $ Terapia_previa : chr "SI" "NO" "SI" "NO" ...
 $ Unidades_transfundidas : int 6 2 1 2 3 1 2 4 1 2 ...
 $ Gleason_quirurgico : chr NA "Gleason 7" NA "Gleason 7"
 ...
 $ Terapia_adyuvante : chr "NO" "NO" "NO" "NO" ...
 $ Radioterapia_adyuvante : chr "NO" "NO" "NO" "NO"
```

**COMANDO STR** nos da un resumen de todos los datos y las variables de (almac\_sangre\_2). EN ESTE CASO LA DATA LIMPIA

## EXPORTANDO DATA BASE LIMPIA

Para exportar la data base `almac_sangre_2` limpia

```
{r}
# Exportar como CSV
write.csv(almac_sangre_2, "almac_sangre_2.csv", row.names = FALSE,
fileEncoding = "UTF-8")

# Mensaje de confirmación
cat("Base de datos exportada como: almacen_sangre_2.csv")

Base de datos exportada como: almacen_sangre_2.csv
```

`write.csv(almac_sangre_2, "almac_sangre_2.csv", row.names = FALSE, fileEncoding = "UTF-8")`

- **write.csv()**: Función de R para exportar dataframes a formato CSV
- **almac\_sangre\_2**: El dataframe que queremos exportar (el que limpiaste y corrigiste)
- **"almac\_sangre\_2.csv"**: El nombre del archivo que se creará
- **row.names = FALSE**: Evita que se incluyan los números de fila como primera columna
- **fileEncoding = "UTF-8"**: Codificación UTF-8 para preservar caracteres especiales (tildes, ñ, etc.)

`cat("Base de datos exportada como: almacen_sangre_2.csv")`

- **cat()**: Función para imprimir mensajes en la consola
- **Muestra confirmación** de que la exportación fue exitosa
- **Indica el nombre del archivo** generado: `almacen_sangre_2.csv`