

SISTEMATIZACION





INTEGRANTES

- CASSANE ACEVEDO, NAOMI ADRIANA
- DIEGUEZ TASAYCO, NALLELY MIRELLA
- MOREYRA LLANCARI, DIANA MELISA
- QUISPE BERROCAL LUIGY
- WINCHO ROJAS OMAR



INTRODUCCIÓN

1 ¿Cómo aplicaremos Machine Learning a esta sesión?

Para esta sesión, aplicaremos técnicas de machine learning no supervisado (análisis de conglomerados) a la base de datos "almac_sangre", que contiene información de pacientes con cáncer de próstata. El objetivo es identificar grupos naturales de pacientes que compartan características similares en cuanto a sus parámetros clínicos y de laboratorio.

1.1 Uso de las técnicas de agrupamiento para responder preguntas de investigación en salud

Las técnicas de agrupamiento nos permitirán clasificar a los pacientes en grupos basados en su similitud respecto a variables como edad, volumen prostático, PSA preoperatorio, unidades transfundidas, entre otras. Los grupos encontrados pueden ser utilizados para evaluar diferencias en la recurrencia bioquímica, necesidad de terapias adyuvantes u otros desenlaces clínicos.

2 Análisis de agrupamiento jerárquico (Hierarchical Clustering)

2.1 Sobre el problema para esta sesión

El dataset "almac_sangre" contiene información de pacientes con cáncer de próstata. Incluye variables como edad, volumen prostático, PSA preoperatorio, unidades de sangre transfundidas, y variables relacionadas con la progresión de la enfermedad. El objetivo es aplicar métodos de agrupamiento para identificar patrones naturales entre los pacientes.



2.2 El dataset para esta sesión

2.2.1 Importando los datos

```
{r}
# Cargar los datos
almac_sangre <- import(here("data", "almac_sangre.csv"))
```

2.2.2 Exploración inicial

```
{r}
# Estructura de los datos
glimpse(almac_sangre)

# Resumen estadístico
summary(almac_sangre)
```

Rows: 316
Columns: 20

\$ Grupo_edad_GR	<chr>	"Mayor", "Mayor", "Mayor", "Interme...
\$ Edad_mediana_GR	<int>	25, 25, 25, 15, 15, 25, 25, 10, 10,...
\$ Edad	<dbl>	72.1, 73.6, 67.5, 65.8, 63.2, 65.4,...
\$ Raza_afroamericana	<chr>	"No", "No", "No", "No", "No", "No",...
\$ Historia_familiar	<chr>	"No", "No", "No", "No", "No", "No",...
\$ Volumen_prostata	<dbl>	54.0, 43.2, 102.7, 46.0, 60.0, 45.9...
\$ Volumen_tumoral	<chr>	"Alto", "Alto", "Bajo", "Bajo", "Me...
\$ Estadio_T	<chr>	"T1-T2a", "T2b-T3", "T1-T2a", "T1-T...
\$ Gleason_biopsia	<chr>	"Gleason 8-10", "Gleason 7", "Gleas...
\$ Confinamiento_organo	<chr>	"No", "Sí", "Sí", "Sí", "Sí", "No",...
\$ PSA_preoperatorio	<dbl>	14.08, 10.50, 6.98, 4.40, 21.40, 5...
\$ Terapia_previa	<chr>	"Sí", "No", "Sí", "No", "No", "No",...
\$ Unidades_transfundidas	<int>	6, 2, 1, 2, 3, 1, 2, 4, 1, 2, 2, 2,...
\$ Gleason_quirurgico	<chr>	"No asignado", "Gleason 7", "No asi...
\$ Terapia_adyuvante	<chr>	"No", "No", "No", "No", "No", "No",...
\$ Radioterapia_adyuvante	<chr>	"No", "No", "No", "No", "No", "No",...
\$ Recurrencia_bioquimica	<chr>	"Sí", "Sí", "No", "No", "No", "No",...
\$ Censor	<chr>	"No", "No", "Sí", "Sí", "Sí", "Sí",...
\$ Tiempo_hasta_recurrencia	<dbl>	2.67, 47.63, 14.10, 59.47, 1.23, 74...
\$ BN_positivo	<chr>	"No", "No", "No", "No", "No", "No",...

Grupo_edad_GR	Edad_mediana_GR	Edad
Length:316	Min. :10.00	Min. :38.40
Class :character	1st Qu.:10.00	1st Qu.:56.20
Mode :character	Median :15.00	Median :61.85
	Mean :16.71	Mean :61.16

2.3 Preparación de los datos

2.3.1 Solo datos numéricos

Para el análisis de agrupamiento jerárquico usaremos solo variables numéricas relevantes.

```
{r}
# Crear un ID único para cada paciente
almac_sangre <- almac_sangre %>%
  mutate(Paciente_ID = paste0("P", row_number()))

# Seleccionar variables numéricas para el clustering
almac_sangre_1 <- almac_sangre |>
  select(Paciente_ID, Edad, Volumen_prostata, PSA_preoperatorio, Unidades_transfundidas,
         Tiempo_hasta_recurrencia, Edad_mediana_GR) |>
  column_to_rownames("Paciente_ID")

# Verificar la estructura
head(almac_sangre_1)
```

Description: df [6 x 6]					
	Edad <dbl>	Volumen_prostata <dbl>	PSA_preoperatorio <dbl>	Unidades_transfun... <int>	
P1	72.1	54.0	14.08	6	
P2	73.6	43.2	10.50	2	
P3	67.5	102.7	6.98	1	
P4	65.8	46.0	4.40	2	
P5	63.2	60.0	21.40	3	
P6	65.4	45.9	5.10	1	

6 rows | 1-5 of 6 columns

2.3.2 La importancia de estandarizar

Estandarizamos las variables para que todas contribuyan equitativamente al análisis.

```
{r}  
almac_sangre_escalado = scale(almac_sangre_1)
```

Un vistazo a los datos antes del escalamiento:

```
{r}  
head(almac_sangre_1)
```

Description: df [6 × 6]

	Edad <dbl>	Volumen_prostata <dbl>	PSA_preoperatorio <dbl>	Unidades_transfun... <int>	
P1	72.1	54.0	14.08	6	
P2	73.6	43.2	10.50	2	
P3	67.5	102.7	6.98	1	
P4	65.8	46.0	4.40	2	
P5	63.2	60.0	21.40	3	
P6	65.4	45.9	5.10	1	

6 rows | 1-5 of 6 columns

y un vistazo después del escalamiento:

```
{r}  
head(almac_sangre_escalado)
```


```
      Edad volumen_prostata PSA_preoperatorio Unidades_transfundidas  
P1 1.5113694      -0.08107066      0.9815876      1.8660551  
P2 1.7185440      -0.43870486      0.3854605      -0.2399214  
P3 0.8760339       1.53159468     -0.2006757      -0.7664155  
P4 0.6412360      -0.34598488     -0.6302868      -0.2399214  
P5 0.2821334       0.11761501       2.2004843       0.2865728  
P6 0.5859894      -0.34929631     -0.5137256      -0.7664155  
Tiempo_hasta_reurrencia Edad_mediana_GR  
P1 -1.0591440       1.3200263  
P2  0.5151523       1.3200263  
P3 -0.6589170       1.3200263  
P4  0.9297357      -0.2720665  
P5 -1.1095663      -0.2720665  
P6  1.4630216       1.3200263
```

2.4 Cálculo de distancias

```
{r}  
dist_almac_sangre <- dist(almac_sangre_escalado, method = "euclidean")
```

2.4.1 Visualizando las distancias euclidianas con un mapa de calor

```
{r}  
fviz_dist(dist_almac_sangre)
```



2.5 El método de agrupamiento: función de enlace (linkage)


```
{r}  
dist_link_almac_sangre <- hclust(d = dist_almac_sangre, method = "ward.D2")
```

2.5 El método de agrupamiento: función de enlace (linkage)

```
{r}  
dist_link_almac_sangre <- hclust(d = dist_almac_sangre, method = "ward.D2")
```


2.7 Dendrogramas para la visualización de patrones

```
{r}  
fviz_dend(dist_link_almac_sangre, cex = 0.5)
```



2.8 ¿Cuántos grupos se formaron en el dendrograma?

```
{r}  
fviz_dend(dist_link_almac_sangre,  
  k = 3,  
  cex = 0.4,  
  k_colors = c("#2E9FDF", "#E7B800", "#FC4E07"),  
  color_labels_by_k = TRUE,  
  rect = TRUE)
```



3 Agrupamiento con el algoritmo K-Means

3.1 El problema y dataset para este ejercicio

Usaremos el mismo dataset preparado anteriormente.

3.2 Estimando el número óptimo de clusters

Primero escalamos los datos (ya lo hicimos anteriormente):


```
{r}
# Escalar los datos para el análisis k-means
# Eliminar filas con valores NA antes de escalar
almac_sangre_clean <- almacen_sangre_1[complete.cases(almacen_sangre_1), ]
almacen_sangre_escalado <- scale(almacen_sangre_clean)
```



Ahora graficamos la suma de cuadrados dentro de los clusters:

```
{r}
# Alternativa: usar menos variables si hay problemas de dimensionalidad
almac_sangre_reduced <- almac_sangre_clean[, c("Edad", "PSA_preoperatorio", "Unidades_transfundidas")]
almac_sangre_escalado_reduced <- scale(almac_sangre_reduced)

fviz_nbclust(almac_sangre_escalado_reduced, kmeans, nstart = 25, method = "wss") +
  geom_vline(xintercept = 3, linetype = 2)
```





3.3 Cálculo del agrupamiento k-means

```
{r}
set.seed(123)
km_res <- kmeans(almac_sangre_escalado, 3, nstart = 25)
```

```
{r}
km_res
```

K-means clustering with 3 clusters of sizes 182, 28, 94


Cluster means:


	Edad	Volumen_prostata	PSA_preoperatorio	Unidades_transfundidas
1	0.02135383	-0.1041875	-0.26247682	-0.06536776
2	0.27920915	1.3713996	2.01467679	1.36959493
3	-0.12451334	-0.2067773	-0.09191669	-0.28140134

	Tiempo_hasta_recurrencia	Edad_mediana_GR
1	0.03179719	-0.680612391
2	-0.38575816	-0.008556663
3	0.05334192	1.320330231

Clustering vector:

P1	P2	P3	P4	P5	P6	P7	P8	P9	P10	P11	P12	P13	P14	P15	P16	P17
2	3	3	1	2	3	3	1	1	1	1	1	1	2	3	1	1
P18	P19	P20	P21	P22	P23	P24	P25	P26	P27	P28	P29	P30	P31	P32	P33	P34
1	1	1	1	1	3	1	1	3	3	1	2	1	3	3	3	1
P35	P36	P37	P38	P39	P40	P41	P42	P43	P44	P46	P47	P48	P49	P50	P51	P52
3	1	3	1	1	1	3	3	1	2	1	1	3	1	1	2	1
P53	P54	P55	P56	P57	P58	P59	P60	P61	P62	P63	P64	P65	P66	P67	P68	P69
1	2	1	1	1	1	3	3	1	1	1	1	3	3	3	1	1
P70	P71	P72	P73	P74	P75	P76	P77	P78	P79	P80	P81	P82	P83	P84	P85	P86
3	1	3	2	3	3	1	1	1	3	1	1	1	2	3	1	1
P87	P88	P89	P90	P91	P92	P93	P94	P96	P97	P98	P99	P101	P102	P103	P104	P105
1	1	1	3	1	1	3	1	1	2	1	1	1	1	2	3	1
P106	P107	P108	P109	P110	P112	P113	P114	P116	P117	P118	P119	P120	P121	P122	P123	P124
1	2	3	1	1	1	1	1	1	1	1	3	3	3	1	1	3
P125	P126	P127	P128	P129	P130	P131	P132	P133	P134	P135	P136	P137	P138	P139	P140	P141
1	1	1	1	1	1	1	2	1	3	1	1	3	3	3	1	3
P142	P143	P144	P146	P147	P148	P149	P150	P151	P152	P153	P154	P155	P156	P157	P158	P159
1	1	3	3	1	1	1	3	2	3	1	3	1	1	2	1	1
P160	P161	P162	P163	P164	P165	P166	P167	P168	P169	P170	P171	P172	P173	P174	P175	P176
1	2	1	3	3	1	1	3	1	1	3	3	1	1	1	1	1
P177	P178	P179	P180	P181	P182	P183	P184	P185	P186	P187	P188	P189	P190	P192	P193	P194
1	3	1	1	1	3	1	1	1	1	1	3	3	1	1	2	3
P195	P196	P197	P198	P199	P200	P201	P202	P203	P204	P205	P206	P207	P208	P209	P210	P211
3	1	1	1	1	1	2	3	3	3	1	3	1	1	1	2	1
P213	P214	P215	P216	P217	P218	P219	P220	P221	P222	P223	P224	P225	P226	P227	P228	P229
1	1	2	1	1	1	1	3	3	1	1	1	1	3	1	1	3





3.4.1 ¿Cómo interpretar?

El gráfico muestra la distribución de los pacientes en los tres grupos identificados. Cada grupo representa pacientes con características similares en términos de las variables incluidas en el análisis.

3.5 Análisis de las características de cada cluster

```
{r}
# Añadir la asignación de clusters al dataset original
# Primero crear un dataframe con los IDs y clusters
clusters_df <- data.frame(
  Paciente_ID = rownames(almac_sangre_clean),
  cluster = km_res$cluster
)

# Unir con el dataset original usando el ID del paciente
almac_sangre_clusters <- almacen_sangre %>%
  mutate(Paciente_ID = paste0("P", row_number())) %>%
  left_join(clusters_df, by = "Paciente_ID")

# Resumen de características por cluster
caracteristicas_clusters <- almacen_sangre_clusters %>%
  group_by(cluster) %>%
  summarise(
    n_pacientes = n(),
    Edad_promedio = mean(Edad, na.rm = TRUE),
    Volumen_prostata_promedio = mean(Volumen_prostata, na.rm = TRUE),
    PSA_preoperatorio_promedio = mean(PSA_preoperatorio, na.rm = TRUE),
    Unidades_transfundidas_promedio = mean(Unidades_transfundidas, na.rm = TRUE),
    Tiempo_recurrencia_promedio = mean(Tiempo_hasta_recurrencia, na.rm = TRUE),
    .groups = 'drop'
  )

print(caracteristicas_clusters)
```

A tibble: 4 x 7

cluster <int>	n_pacientes <int>	Edad_promedio <dbl>	Volumen_prostata <dbl>	PSA_preoperatorio <dbl>
1	182	61.16484	53.34780	6.691593
2	28	63.03214	98.10357	20.500000
3	94	60.10851	50.23617	7.725851
NA	12	64.88333	50.40000	4.872222

4 rows 1-5 of 7 columns



COPARACIÓN ENTRE CLUSTERS


Recurrencias disponibles:

Los clusters 4, 6, 8 y 10 muestran mayor disponibilidad (18-30), mientras que los clusters 3, 5, 7 y 9 presentan menor disponibilidad (2-5).

Clausura en línea:

Los clusters se distribuyen en diferentes rangos (0-7 hasta 0-15), mostrando distintos patrones de comportamiento en el cierre de procesos.

Esta comparación revela clusters con perfiles diferenciados en ambas variables categóricas.



Interpretación de resultados

Basándonos en el análisis realizado:

4.1 Características de los Clusters

Cluster 1 (182 pacientes - 57.6%):

- Perfil: Grupo más numeroso, probablemente pacientes con enfermedad de menor riesgo
- Recurrencia bioquímica: 24 pacientes (13.2%) presentaron recurrencia
- Gleason: Mayoría con Gleason 0-6 (61.5%), seguido de Gleason 7 (29.7%)

Cluster 2 (28 pacientes - 8.9%):

- Perfil: Grupo de alto riesgo, menor cantidad de pacientes pero con peor pronóstico
- Recurrencia bioquímica: 10 pacientes (35.7%) presentaron recurrencia (más del doble que el cluster 1)
- Gleason: Distribución más balanceada, con mayor proporción de Gleason 8-10 (21.4%)

Cluster 3 (94 pacientes - 29.7%):

- Perfil: Grupo de riesgo intermedio
- Recurrencia bioquímica: 16 pacientes (17.0%) presentaron recurrencia
- Gleason: Predominio de Gleason 0-6 (61.7%), similar al cluster 1 pero con peores outcomes

4.2 Implicaciones Clínicas

1. Cluster 2 representa el grupo de mayor riesgo con:

- Mayor tasa de recurrencia bioquímica (35.7%)
- Mayor proporción de Gleason alto (21.4%)
- Podría beneficiarse de seguimiento más estrecho y terapias más agresivas

2. Cluster 1 muestra el mejor perfil pronóstico con:

- Menor tasa de recurrencia (13.2%)
- Mayor proporción de Gleason bajo (61.5%)


3. Cluster 3 presenta características intermedias que requieren evaluación individualizada

4.3 Utilidad del Análisis de Clustering

El análisis identificó tres subgrupos naturales de pacientes con cáncer de próstata que difieren en su perfil de riesgo y características patológicas. Esta estratificación podría ser útil para:

- Personalizar estrategias de seguimiento
- Optimizar asignación de recursos
- Identificar pacientes que requieren intervenciones más intensivas

Limitaciones: Este es un análisis exploratorio y los resultados deben validarse en estudios prospectivos antes de su implementación clínica.



CONCLUSIONES

Dieguez Tasayco: Se identificaron 3 subgrupos naturales de pacientes con cáncer de próstata mediante análisis de clustering.

Cassane Acevedo: El Cluster 2 mostró mayor riesgo con 35.7% de recurrencia versus 13.2% en el Cluster 1.

Moreyra Llancari: Existe correlación con Gleason: mayor proporción de Gleason alto en clusters de peor pronóstico.

Quispe Berrocal: La metodología es efectiva para estratificación beyond clasificaciones tradicionales.

Wincho Rojas: Potencial aplicación clínica en personalización de seguimiento y tratamiento.



Gracias