

DOCUMENTACION DE LA EXPLORACION DE LOS DATOS IMPUTADOS

DOCENTE:

- SEGUNDO VICENTE CASTRO LOPEZ

CURSO:

SISTEMATIZACIÓN Y MÉTODOS
ESTADÍSTICOS

ICA - PERÚ
2025

INTEGRANTES:

- CASSANE ACEVEDO, NAOMI ADRIANA
- DIEGUEZ TASAYCO, NALLELY MIRELLA
- MOREYRA LLANCARI, DIANA MELISA
- QUISPE BERROCAL LUIGY
- WINCHO ROJAS OMAR



INTRODUCCIÓN

El paquete MICE (Multivariate Imputation by Chained Equations) es una herramienta del lenguaje R utilizada para imputar datos faltantes en bases de datos, especialmente cuando los valores ausentes aparecen en múltiples variables al mismo tiempo.

En estudios reales, es muy común encontrar valores perdidos. Ignorarlos o eliminarlos puede reducir el tamaño de la muestra y generar sesgos. Por eso, MICE ofrece una forma estadísticamente robusta de "completar" esos datos faltantes.



Datos para este ejercicio


Usaremos `almac_sangre.csv` con datos de pacientes con cáncer de próstata.

```
{r}
# Cargar los datos
data_prostata <- import(here("data", "almac_sangre.csv"))
```

¿Dónde están los valores perdidos?

```
{r}
colsums(is.na(data_prostata))
```

Grupo_edad_GR			Edad_mediana_GR			Edad		
Raza_afroamericana			0			0		
0			Historia_familiar			volumen_prostata		
Estadio_T			0			volumen_tumoral		
13			9			6		
Gleason_biopsia			Confinamiento_organo			PSA_preoperatorio		
Terapia_previa			0			3		
2			Unidades_transfundidas			Gleason_quirurgico		
0			Radioterapia_adyuvante			0		
0			0			0		
0			Recurrencia_bioquimica			Terapia_adyuvante		
BN_positivo			0			0		
0			0			0		
			Censor			Tiempo_hasta_recurrencia		
			0			1		



Comparación de participantes con/sin valores perdidos

```
{r}
tabla_psa = data_prostata |>
  select(Edad, Volumen_prostata, PSA_preoperatorio, Recurrencia_bioquimica) |>
  mutate(missing = factor(
    is.na(PSA_preoperatorio),
    levels = c(FALSE, TRUE),
    labels = c("Sin valores perdidos", "Con valores perdidos")
  )) |>
  tbl_summary(by = missing) |>
  bold_labels()

tabla_volumen = data_prostata |>
  select(Edad, Volumen_prostata, PSA_preoperatorio, Recurrencia_bioquimica) |>
  mutate(missing = factor(
    is.na(Volumen_prostata),
    levels = c(FALSE, TRUE),
    labels = c("Sin valores perdidos", "Con valores perdidos")
  )) |>
  tbl_summary(by = missing) |>
  bold_labels()

tabla <- tbl_merge(
  tbls = list(tabla_psa, tabla_volumen),
  tab_spanner = c("**PSA**", "**Volumen**")
)
```

```
{r}
tabla
```

Characteristic	PSA		Volumen	
	Sin valores perdidos N = 313 ¹	Con valores perdidos N = 3 ¹	Sin valores perdidos N = 307 ¹	Con valores perdidos N = 9 ¹
Edad	62 (56, 66)	64 (62, 76)	62 (56, 66)	62 (61, 71)
Volumen_prostata	49 (41, 64)	48 (39, 57)	49 (41, 64)	NA (NA, NA)
Unknown	8	1	0	9
PSA_preoperatorio	6.2 (5.0, 9.0)	NA (NA, NA)	6.2 (5.0, 9.1)	4.5 (4.1, 5.7)
Unknown	0	3	2	1
Recurrencia_bioquimica				
No	261 (83%)	1 (33%)	255 (83%)	7 (78%)
Recurrencia_bioquimica				
No	261 (83%)	1 (33%)	255 (83%)	7 (78%)
Sí	52 (17%)	2 (67%)	52 (17%)	2 (22%)

¹ Median (Q1, Q3); n (%)

Preparar datos para imputación

```
{r}
input_data =
  data_prostata |>
  select(Edad, Volumen_prostata, PSA_preoperatorio, Recurrencia_bioquimica) |>
  mutate(Recurrencia_bioquimica = as.factor(Recurrencia_bioquimica))
```

Imputar datos con `mice()`

```
{r}
names(input_data)
```

	Edad	Volumen_prostata	PSA_preoperatorio
[1]	"Edad"	"Volumen_prostata"	"PSA_preoperatorio"
	"Recurrencia_bioquimica"		


```
{r}
data_imputada =
  mice(
    input_data,
    m = 20,
    method = c("pmm", "pmm", "pmm", "logreg"),
    maxit = 20,
    seed = 3,
    print = F
  )
```

```
{r}
data_imputada
```

```
Class: mids
Number of multiple imputations: 20
Imputation methods:
      Edad      Volumen_prostata      PSA_preoperatorio
Recurrencia_bioquimica      ""      "pmm"      "pmm"
""
PredictorMatrix:
      Edad Volumen_prostata PSA_preoperatorio
Recurrencia_bioquimica
Edad      0      1      1
1
Volumen_prostata      1      0      1
1
PSA_preoperatorio      1      1      0
1
Recurrencia_bioquimica      1      1      1
0
```


Analizar datos imputados

```
{r}  
ggmice(data_imputada, aes(x = .imp, y = PSA_preoperatorio)) +  
  geom_jitter(height = 0, width = 0.25) +  
  geom_boxplot(width = 0.5, size = 1, alpha = 0.55, outlier.shape = NA) +  
  labs(x = "Imputation number")
```



```
{r}  
data_imputada_1 <- complete(data_imputada, "long", include = TRUE)  
  
data_imputada_1 <- data_imputada_1 %>%  
  mutate(imputed = .imp > 0,  
         imputed = factor(imputed,  
                           levels = c(F,T),  
                           labels = c("observado", "Imputado")))  
  
prop.table(table(data_imputada_1$Recurrencia_bioquimica,  
                 data_imputada_1$imputed),  
           margin = 2)
```

	observado	Imputado
No	0.8291139	0.8291139
Sí	0.1708861	0.1708861

Regresión con datos imputados

```
{r}
tabla_multi <-
  data_imputada |>
  with(glm(Recurrencia_bioquimica ~ Edad + Volumen_prostata + PSA_preoperatorio,
           family = binomial(link = "logit"))) |>
  tbl_regression(exponentiate = TRUE) |>
  bold_p(t = 0.05)
```

```
{r}
tabla_multi
```

Characteristic	OR	95% CI	p-value
Edad	1.03	0.99, 1.08	0.2
Volumen_prostata	0.99	0.98, 1.00	0.2
PSA_preoperatorio	1.10	1.05, 1.15	<0.001
Abbreviations: CI = Confidence Interval, OR = Odds Ratio			

- Este análisis de regresión logística en RStudio muestra que, de las tres variables evaluadas (edad, volumen prostático y **PSA preoperatorio**), solo el **PSA preoperatorio** es un predictor estadísticamente significativo (**p < 0.001**) de recurrencia, con un odds ratio de **1.10** que indica que cada unidad de aumento en el PSA incrementa el riesgo de recurrencia en un **10%**; mientras que la edad y el volumen prostático no presentan asociación significativa (p = 0.2) con el resultado clínico estudiado.

Conclusiones

- **Dieguez Tasayco:** El PSA preoperatorio es el único predictor significativo de recurrencia bioquímica en este modelo (**$p < 0.001$**).
- **Ccasane Acevedo:** Por cada unidad de aumento en PSA, el riesgo de recurrencia aumenta en un 10% (**OR = 1.10**).
- **Moreyra Llancari:** La edad no muestra asociación significativa con la recurrencia (**$p = 0.2$**), a pesar de un OR de 1.03.
- **Quispe Berrocal:** El volumen prostático tampoco es predictor significativo ($p = 0.2$), con leve efecto protector no significativo (**OR = 0.99**).
- **Wincho Rojas:** El modelo identifica adecuadamente factores de riesgo clínicamente relevantes, validando la calidad de la imputación realizada.



UNIVERSIDAD PRIVADA
SAN JUAN BAUTISTA

MUCHAS
Gracias

